



UNIVERSIDADE
LUSÓFONA

Deteção de Microplásticos

Trabalho Final de Curso

Relatório Intercalar 1º Semestre

Damien Nazário

Prof. Doutor João Carvalho

Prof. Doutor Daniel Fernandes

Trabalho Final de Curso | Ciência de Dados

www.ulusofona.pt

Direitos de cópia

Deteção de Microplásticos em Amostras de Águas, Copyright de Damien Nazário, Universidade Lusófona.

A Escola de Comunicação, Arquitectura, Artes e Tecnologias da Informação (ECATI) e a Universidade Lusófona (UL) têm o direito, perpétuo e sem limites geográficos, de arquivar e publicar esta dissertação através de exemplares impressos reproduzidos em papel ou de forma digital, ou por qualquer outro meio conhecido ou que venha a ser inventado, e de a divulgar através de repositórios científicos e de admitir a sua cópia e distribuição com objectivos educacionais ou de investigação, não comerciais, desde que seja dado crédito ao autor e editor.

Este documento foi gerado com o processador (pdf/Xe/Lua) Latex.

Capítulo 1

Resumo

A presença de microplásticos nos ecossistemas aquáticos tem vindo a suscitar uma preocupação crescente a nível global, devido às potenciais consequências negativas tanto para a vida marinha como para a saúde humana. Estes pequenos fragmentos de plástico, com dimensões inferiores a 5 milímetros, resultam da degradação de resíduos plásticos maiores ou de fontes primárias, como partículas de cosméticos e fibras têxteis, e têm uma ampla distribuição nos ambientes aquáticos. O seu impacto adverso inclui a ingestão por organismos aquáticos, que pode levar à bioacumulação e, consequentemente, à entrada na cadeia alimentar humana, além de afetar a biodiversidade e os equilíbrios ecológicos.

Neste trabalho final de curso, propõe-se o desenvolvimento de um modelo computacional para a deteção de microplásticos em amostras de água, utilizando tecnologias avançadas de processamento de imagem e aprendizagem automática (*machine learning*). A metodologia baseia-se na aplicação de algoritmos de processamento de imagem capazes de identificar e classificar automaticamente partículas de microplásticos, minimizando assim custos e o tempo associados às técnicas tradicionais de análise manual. Para alcançar este objetivo, o trabalho inclui a recolha e tratamento de dados visuais, o treino de modelos de aprendizagem automática e a validação do desempenho destes sistemas em cenários reais.

Espera-se que os métodos desenvolvidos neste estudo possam contribuir de forma significativa para o avanço das estratégias de monitorização ambiental, fornecendo ferramentas eficazes e escaláveis para a análise de microplásticos em diferentes tipos de ecossistemas aquáticos, como rios, lagos, oceanos e ambientes costeiros. Este trabalho poderá, assim, constituir um contributo importante para a compreensão e mitigação do problema dos microplásticos, alinhando-se com os objetivos de sustentabilidade ambiental e preservação da saúde pública.

Palavras-chave: Microplásticos, Impacto ambiental, Ingestão, Bioacumulação, Processamento de imagem, Aprendizagem automática, Sustentabilidade, Monitorização ambiental, Ecossistemas aquáticos, Poluição plástica

Capítulo 2

Abstract

The presence of microplastics in aquatic ecosystems has become an increasingly global concern due to their potential negative impacts on marine life and human health. These small plastic fragments, measuring less than 5 millimetres, originate from the degradation of larger plastic waste or primary sources such as cosmetic particles and textile fibres and are widely distributed across aquatic environments. Their adverse effects include ingestion by aquatic organisms, leading to bioaccumulation and subsequent entry into the human food chain, in addition to harming biodiversity and ecological balance.

This final project proposes the development of a computational model for detecting microplastics in water samples using advanced image processing techniques and machine learning. The methodology involves applying image processing algorithms capable of automatically identifying and classifying microplastic particles, thereby reducing costs and time associated with traditional manual analysis techniques. To achieve this goal, the study encompasses data acquisition and visual processing, training machine learning models, and validating the performance of these systems in real-world scenarios.

The methods developed in this research are expected to significantly advance environmental monitoring strategies by providing efficient and scalable tools for analysing microplastics in various aquatic ecosystems, including rivers, lakes, oceans, and coastal areas. This work aims to make a meaningful contribution to understanding and mitigating the microplastics issue, aligning with environmental sustainability goals and public health preservation.

Keywords: Microplastics, Environmental impact, Ingestion, Bioaccumulation, Image processing, Machine learning, Sustainability, Environmental monitoring, Aquatic ecosystems, Plastic pollution

Conteúdo

1	Resumo	2
2	Abstract	3
	Conteúdo	4
	Lista de Figuras	6
	Lista de Tabelas	7
3	Estado da Arte	8
3.1	Análise de Viabilidade Metodológica	8
3.2	Métodos para Amostragem e Deteção de Microplásticos em Água e Sedi- mentos	9
3.2.1	Recolha de Amostras	9
3.2.2	Separação e Digestão de Microplásticos	10
3.2.3	Identificação e Caracterização Química	10
3.2.4	Mitigação de Contaminação Cruzada	10
3.2.5	Necessidade de Padronização	11
4	Identificação do Problema	12
4.1	Enquadramento	12
5	Benchmarking	15
5.1	Métodos para Processamento de Imagem	15
5.1.1	Revisão da Literatura sobre o YOLO	15
5.1.2	Diferenças entre o YOLO e RNN's Tradicionais	15
5.1.3	Métodos de Treino no YOLO	16
5.1.4	Características de Velocidade do YOLO	16
5.1.5	Contribuições Relevantes para a Deteção de Objetos	16
6	Viabilidade e Pertinência	18
6.1	Viabilidade	18
6.1.1	Viabilidade Técnica	18
6.1.2	Viabilidade Económica	18
6.1.3	Viabilidade Operacional	19
6.2	Pertinência e Relevância	20
6.2.1	Impacto Ambiental	21
6.2.2	Relevância Política e Educativa	21
7	Metodologia	22
7.1	Metodologia Experimental	22
8	Solução Proposta	25
8.1	Tecnologias Seleccionadas	25
8.1.1	Processamento de Imagem e Machine Learning	25
8.1.2	Plataformas de Desenvolvimento	25
8.1.3	Etiquetagem das Imagens	26

8.1.4	Processo de Etiquetagem	26
8.2	Justificação das Escolhas Tecnológicas	27
8.3	Aplicação das Áreas Científicas e Disciplinas	27
8.4	Perspetivas Futuras	27
9	Calendário	29
9.1	Planeamento Detalhado	29
9.2	Cronograma	29
9.3	Acompanhamento e Reavaliação	30
9.4	Conclusão	30
	Bibliografia	31

Lista de Figuras

4.1	Panorama das possibilidades de métodos analíticos para a determinação de microplásticos no ambiente.	13
6.1	Câmara microscópica Accu-Scope SKYE	19
6.2	Cabos Ethernet submersíveis	19
6.3	Ligação elétrica submersível	19
6.4	Cage protetora submersível	19
7.1	Fluxograma do procedimento experimental para a deteção de microplásticos	24
8.1	Exemplo do processo de etiquetagem de microplásticos utilizando a plataforma <i>MakeSense</i> . Cada microplástico identificado é destacado e rotulado com precisão, permitindo a criação de um conjunto de dados anotados para o treino de modelos de <i>machine learning</i>	26
9.1	Cronograma Gantt do plano de trabalho remanescente.	29

Lista de Tabelas

4.1	Comparação de Métodos de Deteção de Microplásticos	14
6.1	Comparação de Custos entre Métodos Tradicionais e Automatizados . . .	20

Capítulo 3

Estado da Arte

A utilização massiva de plásticos, particularmente os de uso único, tornou-se uma característica marcante da era moderna, trazendo consigo impactos ambientais, sociais e económicos alarmantes. Estima-se que metade de todo o plástico produzido globalmente seja destinado a aplicações de uso único, como embalagens descartáveis, cuja vida útil é efemeramente curta. Esses produtos, frequentemente fabricados a partir de matérias-primas fósseis, são descartados em proporções alarmantes: apenas 10% do plástico produzido é reciclado¹, uma parte significativa acaba por poluir ecossistemas terrestres e aquáticos.

O aumento exponencial da produção de plásticos nas últimas décadas intensificou a crise ambiental associada a este material. Entre as décadas de 1970 e 1990, a geração de resíduos plásticos triplicou, e a tendência de crescimento continua alarmante. Segundo as Nações Unidas, projeta-se que, até 2050, a produção global de plásticos poderá ultrapassar 1.100 milhões de toneladas anuais [Pro20], caso os padrões de consumo e produção atuais se mantenham. Adicionalmente, cerca de 36% de todo o plástico produzido é destinado a embalagens, sendo que aproximadamente 85% deste volume acaba em aterros sanitários ou é descartado de forma inadequada.

Essa crise é agravada pela contribuição dos sistemas fluviais, que atuam como vias de transporte de resíduos plásticos para os oceanos. Estima-se que cerca de 1.000 rios sejam responsáveis por até 80% das emissões plásticas fluviais globais, sublinhando a importância de ações locais e regionais para mitigar impactos de escala global.

Dada a magnitude do problema, torna-se essencial compreender os métodos atuais de monitorização e mitigação de microplásticos, bem como impulsionar o desenvolvimento de soluções tecnológicas inovadoras. Estas iniciativas são cruciais para enfrentar, de forma eficaz, um dos mais prementes desafios ambientais do século XXI.

3.1 Análise de Viabilidade Metodológica

A deteção de microplásticos em ecossistemas aquáticos tem evoluído significativamente devido à crescente consciencialização sobre os seus impactos ambientais e na saúde pública. Estudos recentes, como os de Campos-Lopez et al.[Cam+24], sublinham a relevância de metodologias automatizadas e precisas para identificar e quantificar microplásticos, superando as limitações das técnicas tradicionais, geralmente morosas, dispendiosas e suscetíveis a erros humanos.

Entre os avanços mais relevantes neste campo destaca-se o uso de técnicas de Processamento Digital de Imagens (DIP), em conjunto com métodos avançados, como a Análise de Dimensões Fractais (FDA) e os Métodos de Aproximação Polinomial (PA). Estas abordagens melhoram significativamente a precisão na segmentação e classificação das partículas de microplásticos, otimizando resultados. Por exemplo, técnicas como equalização de histogramas e filtros adaptativos reduzem o ruído nas imagens enquanto preservam características essenciais das partículas, como contornos e texturas.

¹United Nations Environment Programme (2021). From Pollution to Solution: A global assessment of marine litter and plastic pollution. Nairobi.

Ferramentas portáteis de microscopia digital têm igualmente impulsionado a capacidade de realizar análises diretamente em campo. Estes dispositivos permitem a aquisição controlada de imagens de alta resolução, aumentando a fiabilidade e a eficiência dos métodos de deteção.

Paralelamente, métodos baseados em aprendizagem automática, como Máquinas de Vetores de Suporte (SVM) e Redes Neurais Convolucionais (CNN), têm demonstrado elevado potencial na classificação automatizada de microplásticos. Estas técnicas são particularmente eficazes na identificação de padrões complexos, como formas irregulares e texturas diferenciadas. As CNNs destacam-se pela sua abordagem de aprendizagem "end-to-end", simplificando o fluxo de trabalho e reduzindo a necessidade de intervenção manual.

Apesar dos progressos alcançados, subsistem desafios significativos. A variabilidade nas formas e tamanhos dos microplásticos, aliada à heterogeneidade dos ambientes aquáticos, exige métodos que combinem precisão, escalabilidade e robustez. Investigações futuras deverão concentrar-se no desenvolvimento de tecnologias multiespectrais e sistemas em tempo real, promovendo soluções práticas para a monitorização ambiental em larga escala.

Estes avanços metodológicos refletem a necessidade de abordagens multidisciplinares, integrando ciência dos materiais, computação e engenharia ambiental, para enfrentar os desafios associados aos microplásticos de forma sustentável e eficaz.

3.2 Métodos para Amostragem e Deteção de Microplásticos em Água e Sedimentos

A deteção de microplásticos em ambientes aquáticos e sedimentares é um processo complexo, condicionado pela ausência de protocolos uniformizados. Segundo Prata et al. [Pra+19], esta falta de padronização compromete a representatividade e a comparabilidade dos resultados. Esta secção aborda as etapas principais no tratamento de amostras de água e sedimentos, destacando os avanços metodológicos e os desafios ainda por superar.

3.2.1 Recolha de Amostras

A recolha de amostras constitui a primeira etapa, sendo determinante para garantir a representatividade dos dados. A escolha do método depende do tipo de amostra (água ou sedimento) e dos objetivos do estudo.

Para amostras de água, os métodos amplamente usados incluem:

- **Redes de manta e neuston:** Utilizadas para recolha de amostras em superfície e sub-superfície. Redes de malha fina (100 µm) detetam concentrações até cem vezes superiores, mas são mais suscetíveis a entupimentos devido a matéria orgânica.
- **Bombas e sistemas de filtração:** Ideais para amostras em locais costeiros ou profundos. Contudo, há maior risco de contaminação cruzada.
- **Garrafas de vidro:** Reduzem a contaminação por plásticos, embora limitem o volume de amostras recolhidas.

Para amostras de sedimentos:

- **Métodos manuais:** Utilizam-se pinças para recolher partículas na superfície de praias.

- **Equipamentos especializados:** Dispositivos como *grab samplers* e *box corers* são usados para recolha de sedimentos submersos e profundos.
- **Representatividade:** Requer volumes entre 25g e 3 kg e réplicas (mínimo de cinco por local, segundo a MSFD²).

3.2.2 Separação e Digestão de Microplásticos

A separação e digestão de microplásticos são etapas essenciais para eliminar materiais orgânicos e minerais sem danificar as partículas plásticas:

- **Redução de Volume:** Inclui filtração e malhas para remover partículas maiores.
- **Separação por Densidade:** Utiliza soluções como NaCl (1,2 g/cm³) para partículas leves, enquanto *NaI* ou *ZnCl₂* ($\geq 1,5$ g/cm³) são mais eficazes para polímeros densos.

Para a digestão, os métodos incluem:

- **Agentes oxidantes:** O H_2O_2 (30%) é amplamente utilizado pela sua eficiência.
- **Métodos enzimáticos:** Promissores, mas economicamente limitados.
- **Métodos químicos:** Uso de HNO_3 ou $NaOH$ que requerem cautela para evitar degradação dos polímeros.

3.2.3 Identificação e Caracterização Química

A identificação de microplásticos combina inspeção visual e técnicas avançadas:

- **Inspeção Visual:** Simples e de baixo custo, mas sujeita a erros.
- **Corantes:** Como o Nile Red, que apresenta alta recuperação (>90%), embora exija validação.
- **Técnicas Avançadas:** FTIR e Raman são ideais para caracterização química, complementando métodos como *Pyro-GC-MS*.

3.2.4 Mitigação de Contaminação Cruzada

Para reduzir contaminações durante o processamento:

- Usar equipamentos de vidro ou metal.
- Evitar roupas sintéticas.
- Filtrar soluções e manter amostras cobertas.
- Trabalhar em ambientes controlados, como capelas de exaustão.

²A *EU Marine Strategy Framework Directive* foi criada para proteger o ecossistema marinho e a biodiversidade, fundamentais para as atividades económicas e sociais relacionadas com a saúde e o meio marinho.

3.2.5 Necessidade de Padronização

A padronização de protocolos é apontada como uma prioridade essencial para a investigação na área de microplásticos. Conforme analisado por Prata et al. [Pra+20], esta necessidade abrange

- Tamanhos de malha ou filtro.
- Volumes mínimos de amostras.
- Procedimentos claros de separação e digestão.
- Métodos validados para identificação química e visual.

A uniformização de metodologias permitirá maior comparabilidade entre estudos e uma compreensão mais aprofundada do impacto ambiental dos microplásticos.

Capítulo 4

Identificação do Problema

O presente Trabalho Final de Curso (TFC) tem como objetivo o desenvolvimento de um modelo computacional inovador para a deteção de microplásticos em amostras de água, abordando as limitações associadas aos métodos tradicionais e contribuindo para a monitorização ambiental. Este trabalho procura explorar a aplicação de algoritmos de *machine learning* e processamento de imagem, com vista a desenvolver uma abordagem que aumente não apenas a precisão, mas também a eficiência e a escalabilidade do processo. Assim, pretende-se disponibilizar ferramentas mais robustas que possam ser aplicadas na investigação científica e na gestão ambiental.

A poluição por microplásticos emergiu como uma das maiores ameaças ambientais das últimas décadas, com impactos profundos nos ecossistemas aquáticos e potenciais riscos para a saúde humana (Thompson et al., 2004). Definem-se os microplásticos como partículas plásticas com um diâmetro inferior a 5 mm¹, geralmente resultantes da degradação de plásticos maiores. Estas partículas são facilmente transportadas pelas correntes de água, acumulando-se em rios, lagos e oceanos, o que as torna um problema ambiental global.

O impacto adverso dos microplásticos nos ecossistemas aquáticos está amplamente documentado (Cox et al., 2019). Estas partículas podem ser ingeridas por organismos aquáticos, causando danos à biodiversidade e comprometendo as cadeias alimentares, com potenciais consequências para a saúde humana. Além disso, os microplásticos podem atuar como vetores de poluentes químicos, exacerbando os efeitos tóxicos nos organismos e nos ecossistemas.

A deteção e quantificação de microplásticos apresentam, contudo, desafios significativos. Os métodos tradicionais, como a filtragem química e a espectroscopia no infravermelho (FTIR), são reconhecidos pela sua precisão, mas também pela morosidade, elevados custos e incapacidade de lidar com grandes volumes de amostras. Adicionalmente, a diversidade de formas, tamanhos e composições químicas das partículas dificulta ainda mais os processos analíticos.

Neste contexto, este TFC propõe uma abordagem automatizada baseada em técnicas de ciência de dados, incluindo *machine learning* e processamento de imagem, para melhorar a precisão e a eficiência na deteção de microplásticos em diferentes ambientes aquáticos. Espera-se que esta metodologia forneça uma base sólida para uma monitorização ambiental mais abrangente e eficaz.

4.1 Enquadramento

A deteção de microplásticos evoluiu substancialmente nas últimas décadas, com métodos físicos e químicos tradicionais a desempenharem um papel crucial. Contudo, estas técnicas apresentam limitações em termos de tempo, custos e capacidade de análise de grandes volumes de amostras. Em particular, a deteção de partículas com dimensões reduzidas ou estruturas complexas continua a ser um desafio.

¹Agência Portuguesa do Ambiente (APA). (2024). *Microplásticos*. <https://apambiente.pt/residuos/microplasticos>

Com o avanço da ciência de dados, surgiram novas possibilidades para otimizar e automatizar este processo. Modelos computacionais baseados em *machine learning* e processamento de imagem oferecem uma alternativa promissora, permitindo maior precisão, eficiência e escalabilidade na análise. Assim, conforme ilustrado na Figura 4.1, existem diversas abordagens analíticas atualmente disponíveis para a determinação de microplásticos no ambiente, que englobam desde métodos tradicionais a técnicas inovadoras baseadas em inteligência artificial.

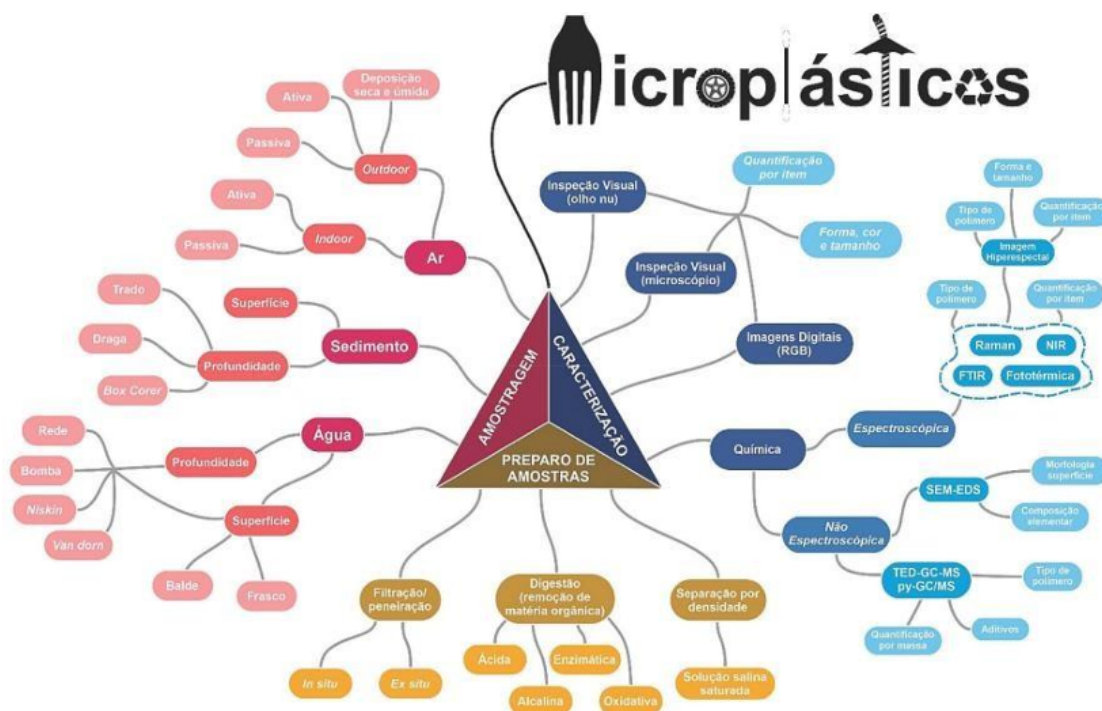


Figura 4.1: Panorama das possibilidades de métodos analíticos para a determinação de microplásticos no ambiente.

Comparar estas abordagens inovadoras com os métodos tradicionais é essencial para compreender as suas vantagens, limitações e impacto potencial na monitorização ambiental. Segue-se, na Tabela 4.1, uma análise comparativa entre os métodos convencionais e as abordagem automatizada proposta neste TFC.

Tabela 4.1: Comparação de Métodos de Detecção de Microplásticos

Método	Vantagens	Desvantagens
Filtragem e Separação Física	Simplicidade operacional. Possibilidade de aplicação em campo.	Demorado para grandes volumes. Limitações na detecção de partículas muito pequenas.
Inspeção Visual	Simple e acessível para partículas maiores. Não requer equipamento especializado.	Subjetivo e dependente da experiência do operador. Ineficaz para partículas pequenas ou transparentes.
Microscopia Óptica/Eletrónica	Visualização detalhada de partículas. Alta resolução para microplásticos pequenos.	Custos elevados. Demorado e ineficiente para grandes volumes. Requer equipamentos sofisticados.
Espectroscopia Infravermelha (FTIR)	Alta precisão na identificação de polímeros. Eficaz para partículas muito pequenas.	Equipamento caro. Procedimento moroso e não escalável.
Espectroscopia de Raman	Sensibilidade molecular. Identificação detalhada de partículas.	Equipamento complexo e caro. Pode exigir preparação específica de amostras.
Pirólise-GC-MS	Alta precisão na análise química. Útil para polímeros complexos.	Técnica decompõe termicamente as partículas Custo elevado. Exige elevado conhecimento técnico.
Modelo Computacional (Machine Learning)	Automatização do processo. Capacidade para analisar grandes volumes de dados. Aprendizagem contínua com novos dados.	Necessita de grandes quantidades de dados etiquetados. Requer recursos computacionais.
Processamento de Imagem	Detecção de partículas pequenas e transparentes. Processo repetível e escalável.	Depende da qualidade das imagens e dos dados de entrada. Menor precisão para identificar polímeros específicos.

Capítulo 5

Benchmarking

5.1 Métodos para Processamento de Imagem

Nos últimos anos, a detecção de objetos consolidou-se como uma das áreas fundamentais no campo da inteligência artificial, com aplicações diversificadas em sectores como segurança, saúde, transportes e finanças. Um dos algoritmos mais destacados nesta área é o *You Only Look Once* (YOLO), reconhecido pela sua capacidade de realizar detecção de objetos em tempo real de forma eficiente e precisa [Red+16].

5.1.1 Revisão da Literatura sobre o YOLO

A evolução do YOLO tem sido amplamente investigada em diversos estudos, destacando-se pela sua relevância na área de detecção de objetos em tempo real. Um exemplo notável é o artigo de Jiang et al. [Jia+22], que realiza uma análise detalhada das sucessivas versões do algoritmo, desde o YOLO v1 até ao YOLO v5. Este estudo aborda as melhorias incrementais introduzidas em cada versão, enfatizando avanços como a detecção em múltiplas escalas, o uso de redes residuais e a otimização para cenários de tempo real. Além disso, o trabalho compara o desempenho do YOLO com outras metodologias baseadas em Redes Neurais Convolucionais (CNNs), evidenciando as vantagens do YOLO em termos de eficiência e precisão.

As principais melhorias nas versões do YOLO incluem:

- **YOLO v2:** Introduziu a normalização de lotes (*batch normalization*) e classificadores de alta resolução, melhorando a precisão e a rapidez na detecção.
- **YOLO v3:** Implementou a detecção em múltiplas escalas e redes residuais, permitindo a detecção eficaz de objetos com diferentes tamanhos.
- **YOLO v4:** Incorporou técnicas inovadoras, como a *Spatial Pyramid Pooling* (SPP) e a ativação *MISH*, proporcionando um desempenho superior.
- **YOLO v5:** Enfatizou a usabilidade, com um foco em resultados em tempo real e modelos ajustáveis às necessidades de precisão e recursos computacionais.

5.1.2 Diferenças entre o YOLO e RNN's Tradicionais

Uma diferença essencial entre o YOLO e as CNNs tradicionais reside na abordagem para a detecção de objetos. Enquanto as CNNs convencionais se concentram na classificação, o YOLO trata a detecção como um problema de regressão, prevendo diretamente as caixas delimitadoras (*bounding boxes*) e as probabilidades de cada classe a partir de uma única imagem. Esta abordagem elimina a necessidade de múltiplas passagens ou regiões de interesse, comuns nas técnicas tradicionais, e possibilita uma detecção em tempo real.

Além disso, o YOLO processa a imagem inteira numa única passagem pela rede, utilizando uma codificação global que reduz os erros na detecção de objetos em segundo plano.

5.1.3 Métodos de Treino no YOLO

O treino do YOLO envolve várias etapas cruciais:

- As imagens de entrada são redimensionadas para tamanhos padronizados (224×224 píxeis inicialmente, seguidos de 448×448 píxeis para a detecção final).
- A configuração do modelo inclui a remoção da última camada de convolução e a adição de três camadas com 1024 filtros, adaptando a rede à tarefa específica de classificação.
- O treino decorre em duas fases: uma inicial, com imagens de baixa resolução, para acelerar o processo, e outra, com imagens de alta resolução, para refinar a precisão.

Técnicas como a normalização de lotes e a utilização de classificadores de alta resolução contribuem para a eficácia do modelo.

5.1.4 Características de Velocidade do YOLO

A rapidez do YOLO advém da sua arquitetura simplificada, que permite a previsão direta de caixas delimitadoras e categorias a partir de uma única imagem. O processamento da imagem inteira numa única etapa elimina a necessidade de múltiplas fases, como as exigidas por abordagens tradicionais, e melhora a eficiência temporal.

5.1.5 Contribuições Relevantes para a Detecção de Objetos

YOLO-Inception: Detecção de Objetos Pequenos em Fundos Complexos

O modelo YOLO-Inception, apresentado por Du et al [Du18], introduz uma arquitetura semelhante ao *Inception*, utilizando núcleos de convolução em múltiplas camadas. Este modelo melhora a precisão na detecção de objetos pequenos e agrupados, particularmente em fundos visualmente complexos.

Desempenho do YOLO-Inception:

- **Precisão Média (mAP):** 78,37%, superando o YOLO v3 na detecção de objetos pequenos.
- **Velocidade:** Tempo de processamento de 22 ms por imagem, competitivo com o YOLO v3.

YOLO Nano: Rede Convolucional Compacta para Detecção de Objetos

Com o crescente interesse por soluções eficientes para dispositivos com recursos limitados, surgiram modelos compactos de redes neurais que priorizam a eficiência sem comprometer significativamente a precisão. Nesse contexto, Wong et al. [Won+19] apresentam o YOLO Nano, uma rede convolucional altamente otimizada para cenários com restrições computacionais. Este modelo destaca-se por alcançar um equilíbrio notável entre precisão, tamanho compacto e eficiência energética, tornando-o particularmente adequado para aplicações em dispositivos móveis e sistemas embutidos.

Desempenho do YOLO Nano:

- **Tamanho do Modelo:** 4,0 MB, representando uma redução significativa no tamanho (15,1 vezes menor em comparação ao Tiny YOLO v2), o que facilita a sua implementação em dispositivos com restrições de memória.

- **Precisão Média (mAP):** 69,19% no conjunto de dados VOC 2007, demonstrando um desempenho competitivo em termos de precisão, especialmente considerando a sua compactação.
- **Eficiência Energética:** Altamente otimizado para dispositivos móveis e embutidos, com baixo consumo de recursos, tornando-o ideal para aplicações em tempo real em cenários com recursos computacionais limitados.

Esses avanços reforçam a relevância do YOLO Nano no campo da detecção de objetos, destacando-se pela sua capacidade de equilibrar precisão e eficiência em aplicações práticas, como sistemas móveis e embutidos que exigem desempenho confiável e econômico.

Capítulo 6

Viabilidade e Pertinência

Neste capítulo, procede-se à análise da viabilidade e pertinência do desenvolvimento de um modelo para deteção em tempo real de microplásticos em ambientes marinhos, utilizando câmaras submersas e processamento automatizado de imagem. A integração de Inteligência Artificial (IA) em sistemas de monitorização ambiental destaca-se pela sua capacidade de processamento local (*on-board*), o que reduz substancialmente a necessidade de transmissão constante de dados para servidores centrais. Esta característica é particularmente relevante em ambientes aquáticos, onde as condições podem variar rapidamente. O processamento em tempo real e a monitorização contínua permitem a identificação precoce de focos de poluição por microplásticos, proporcionando dados precisos que suportam ações corretivas imediatas.

A solução proposta visa apresentar um contributo inovador e sustentável, com potencial para ultrapassar o âmbito académico, assegurando a sua continuidade e aplicação prática em contextos reais.

Adicionalmente, a implementação de câmaras submersas em zonas costeiras e fluviais oferece uma análise detalhada das concentrações de microplásticos, contribuindo para a criação de uma base de dados abrangente. Esta base de dados é essencial para a formulação de políticas públicas eficazes e para o desenvolvimento de iniciativas orientadas para a preservação ambiental.

6.1 Viabilidade

A viabilidade do modelo proposto foi analisada com base em critérios técnicos, económicos e operacionais, de modo a garantir que a solução apresentada seja implementável e utilizável em contexto real. A seguir, apresentam-se os principais aspetos dessa análise.

6.1.1 Viabilidade Técnica

O modelo proposto baseia-se na utilização de tecnologias acessíveis, como câmaras digitais microscópicas de alta resolução e algoritmos de inteligência artificial treinados para a identificação de microplásticos. As câmaras submersas podem ser instaladas em boias de monitorização ou em infraestruturas costeiras, garantindo robustez suficiente para operar em condições adversas. A integração de tecnologias de comunicação subaquática poderia assegurar a transmissão dos dados em tempo real para centros de monitorização.

6.1.2 Viabilidade Económica

A análise económica preliminar sugere que o investimento inicial — que inclui a aquisição de câmaras submersas, cabos Ethernet subaquáticos, sensores auxiliares (para medir parâmetros como turbidez e temperatura) e a infraestrutura necessária para o processamento de dados — é competitivo quando comparado com os métodos tradicionais de recolha e análise laboratorial de amostras.

Além disso, o modelo proposto apresenta uma significativa redução nos custos operacionais no longo prazo, uma vez que minimiza a necessidade de recolhas manuais

frequentes e do transporte de amostras para análise laboratorial. Este fator, aliado ao crescente interesse de instituições públicas e privadas em soluções inovadoras para monitorização ambiental — incluindo governos, organizações não governamentais e iniciativas de responsabilidade corporativa — reforça substancialmente a viabilidade económica e estratégica deste projeto. Conforme ilustrado nas Figuras 6.1, 6.2, 6.3 e 6.4 são apresentadas algumas imagens preliminares que exemplificam como um sistema básico de deteção de microplásticos poderia ser implementado. Estas ilustrações oferecem uma visão inicial dos componentes fundamentais que poderiam compor um dispositivo funcional para monitorização ambiental.



Figura 6.1: Câmara microscópica Accu-Scope SKYE



Figura 6.2: Cabos Ethernet submersíveis



Figura 6.3: Ligação elétrica submersível



Figura 6.4: Cage protetora submersível

6.1.3 Viabilidade Operacional

A operacionalização do sistema envolve a integração simples entre hardware (câmaras e sensores) e software (modelos de ML). A modularidade do modelo permite atualizações tecnológicas e adaptações para diferentes ambientes marinhos.

Como ilustrado na Tabela 6.1, os métodos tradicionais de monitorização de microplásticos apresentam algumas limitações económicas e operacionais em comparação com o modelo automatizado proposto.

Tabela 6.1: Comparação de Custos entre Métodos Tradicionais e Automatizados

Aspecto	Métodos Tradicionais	Modelo Automatizado
Custo Inicial	Alto	Moderado
Custo Operacional	Alto	Baixo
Escalabilidade	Limitada	Alta
Tempo de Processamento	Lento	Rápido

Custo Inicial: Os métodos tradicionais requerem investimentos iniciais elevados devido à aquisição de equipamentos laboratoriais especializados e à logística de recolha. Em contrapartida, o modelo automatizado utiliza câmaras submersas e hardware acessível, resultando assim num custo inicial moderado.

Custo Operacional: Os custos operacionais dos métodos tradicionais são significativamente elevados, sobretudo devido à mão de obra intensiva e ao transporte frequente de amostras para laboratórios. O modelo automatizado reduz estes custos, permitindo análises *in situ* e processamento local (*on-board*).

Escalabilidade: A abordagem tradicional enfrenta desafios de escalabilidade, uma vez que depende de recursos humanos e logísticos que aumentam exponencialmente com a área a ser monitorizada. Já o modelo automatizado é altamente escalável, possibilitando a instalação de múltiplas unidades em diferentes locais e a integração dos dados em sistemas centralizados.

Tempo de Processamento: Nos métodos tradicionais, o tempo de processamento é um fator crítico, pois as amostras precisam ser recolhidas, transportadas e analisadas em laboratório. O modelo automatizado destaca-se pela capacidade de realizar processamento em tempo real, otimizando a detecção de focos de poluição e permitindo assim intervenções imediatas.

Esta análise evidencia as vantagens operacionais e económicas do modelo automatizado, reforçando a sua viabilidade como uma alternativa eficiente e sustentável para a monitorização de microplásticos em ambientes marinhos.

Adicionalmente, a questão da autonomia energética foi considerada, sendo possível alimentar as câmaras submersas com painéis solares flutuantes ou baterias de longa duração, garantindo uma operação contínua mesmo em locais remotos.

6.2 Pertinência e Relevância

A pertinência deste projeto está diretamente relacionada com a crescente preocupação global acerca da poluição marinha por microplásticos, que afeta significativamente a biodiversidade, a saúde pública e a sustentabilidade dos ecossistemas marinhos. Estudos indicam que os microplásticos, presentes em objetos do quotidiano como cigarros, roupas e cosméticos, acumulam-se no ambiente, causando danos aos organismos marinhos e representando potenciais riscos para a saúde humana [UNR21].

A implementação do modelo proposto permitirá a identificação precoce de áreas críticas afetadas por microplásticos em ambientes marinhos. Os dados obtidos serão fundamentais para o desenvolvimento de políticas públicas mais eficazes, apoio a iniciativas de mitigação e aumento da conscientização pública sobre a gravidade deste problema. A monitorização precisa e contínua é essencial para compreender a extensão da contaminação por microplásticos e para a formulação de estratégias de intervenção adequadas [Ser21].

Ao fornecer informações detalhadas sobre a distribuição e concentração de microplásticos, o projeto contribuirá para a proteção da biodiversidade marinha e para a promoção da saúde pública, alinhando-se com os objetivos de desenvolvimento sustentável e preservação ambiental.

6.2.1 Impacto Ambiental

A implementação do modelo proposto contribui para a identificação precoce de zonas críticas afetadas por microplásticos em ambientes marinhos. Os dados recolhidos poderão ser utilizados para aprimorar políticas públicas, apoiar iniciativas de mitigação e sensibilizar a sociedade para a gravidade deste problema.

6.2.2 Relevância Política e Educativa

A relevância do projeto é reforçada por iniciativas globais como a campanha *Mares Limpos* do Programa das Nações Unidas para o Meio Ambiente (PNUMA), que tem como foco informar consumidores, impulsionar mudanças políticas e proteger o ambiente. Estas iniciativas destacam a importância de ações coordenadas para conter os impactos negativos dos microplásticos na saúde e na biodiversidade.

Além disso, o projeto alinha-se com as metas da Década da Ciência Oceânica¹ para o Desenvolvimento Sustentável, contribuindo para a aceleração de esforços na mitigação da poluição e na preservação dos ecossistemas marinhos. Ao disponibilizar ferramentas tecnológicas avançadas, o modelo proposto poderá apoiar campanhas educativas e decisões políticas baseadas em dados confiáveis, promovendo mudanças significativas tanto no comportamento humano quanto na gestão ambiental.

¹A Década da Ciência Oceânica é uma iniciativa coordenada pela Comissão Oceanográfica Intergovernamental da UNESCO (IOC/UNESCO), que atua como coordenadora global. A iniciativa é estruturada em torno de dez desafios principais, incluindo o objetivo de alcançar "um oceano limpo", onde as fontes de poluição, como os microplásticos, sejam identificadas, reduzidas ou eliminadas. Para mais informações, vide <https://www.oceandecade.org>.

Capítulo 7

Metodologia

Este capítulo apresenta, de forma detalhada, a metodologia adotada para a realização do ensaio de deteção de microplásticos em condições controladas.

7.1 Metodologia Experimental

O presente estudo seguiu uma abordagem estruturada para simular um ambiente aquático controlado e analisar a concentração de microplásticos. A metodologia envolveu múltiplas etapas descritas a seguir:

- **Recipiente e Preparação do Meio Aquático:** Foi utilizado um recipiente com capacidade de 3 litros, preenchido com água corrente. Este ambiente simula condições de meio aquático controlado, adequado para realizar o teste de concentração de microplásticos.
- **Fragmentação de Plásticos:** Fragmentaram-se 5 gramas de rolhas de plástico de garrafas de água, com ciclos de 2 minutos, de modo a garantir uma gama de partículas de tamanho reduzido e heterogêneo. Este processo de fragmentação visa simular, de maneira controlada, o desgaste natural ao longo do tempo, dos plásticos em ambientes aquáticos.
- **Incremento de Microplásticos:** Foram realizadas adições sucessivas de microplásticos ao recipiente, utilizando uma peneira por forma a impedir a entrada de partículas com dimensões iguais ou superiores a 5 mm. Os incrementos foram realizados em frações de 5 gramas (correspondendo aproximadamente a 2 rolhas de garrafa), até alcançar um total de 25 gramas. Estas etapas foram executadas com concentrações crescentes de 5, 10, 15, 20 e 25 gramas.
- **Recolha de Amostras para Análise:** A cada incremento, recolheu-se uma amostra de 100 ml da água do recipiente utilizando para o efeito um copo esterilizado, para posterior análise microscópica. Esta metodologia de recolha visa assegurar que o processo possa ser replicável, e, que os resultados são consistentes.
- **Captura de Imagens:** Para cada nível de concentração (5g, 10g, 15g, 20g e 25g), foram capturadas 100 imagens, utilizou-se para o efeito o microscópio digital TOM-LOV DM9 com ecrã LCD de 7 polegadas, ampliação de 1000X e resolução de 6 Mp.
- **Reintrodução das Amostras:** Após a recolha de cada amostra de 100 ml, o conteúdo foi devolvido ao recipiente de 3 litros, assegurando que o volume total permanecesse constante ao longo do ensaio. Este procedimento foi repetido de forma sistemática até que a concentração final de 25 gramas de microplásticos fosse atin- gida.

O procedimento descrito, conforme ilustrado no fluxograma da Figura 7.1, assegura uma análise detalhada dos microplásticos em diferentes condições de concentração, em

ambiente controlado, proporcionando assim o conjunto de dados necessário para proceder à avaliação e detecção de microplásticos em água através de imagens.

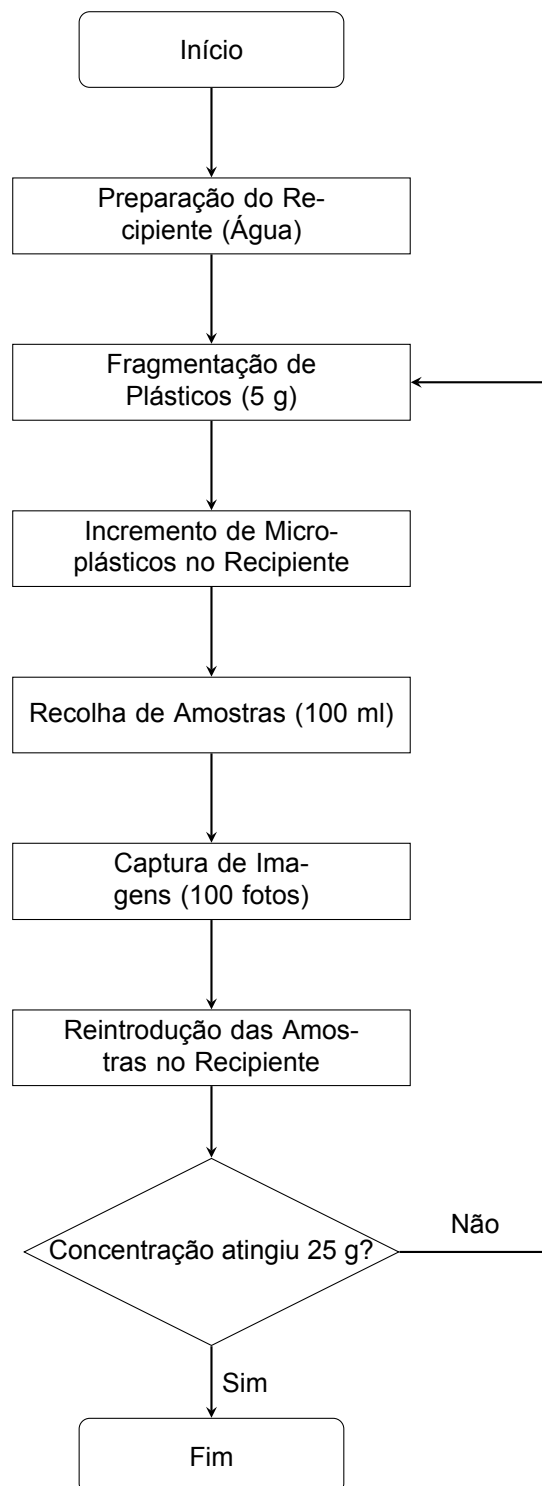


Figura 7.1: Fluxograma do procedimento experimental para a detecção de microplásticos

Capítulo 8

Solução Proposta

O presente Trabalho Final de Curso (TFC) concentra-se, nesta fase inicial, no desenvolvimento de um algoritmo de processamento de imagem para a deteção automatizada de microplásticos em amostras de água. A implementação da infraestrutura de hardware, embora seja um componente relevante para a aplicação prática, ficará fora do escopo temporal deste trabalho e será proposta como uma etapa futura. Assim, o projeto apresenta potencial para continuidade por outros investigadores ou alunos, que poderão explorar a integração de uma estrutura física para aplicação em campo, ampliando o impacto desta solução inicial.

8.1 Tecnologias Selecionadas

8.1.1 Processamento de Imagem e Machine Learning

A escolha do processamento de imagem como tecnologia central é justificada pela sua eficácia na análise de dados visuais complexos, como as características morfológicas e texturais dos microplásticos. Para isso, serão utilizados algoritmos baseados em Redes Neurais Convolucionais (CNNs), com foco em arquiteturas como o YOLO (*You Only Look Once*), dada a sua comprovada eficiência em tarefas de deteção de objetos.

O processamento de imagem permite identificar partículas de microplásticos com precisão, mesmo em cenários de alta variabilidade, como diferentes tamanhos, formas, cores e transparências. As principais vantagens incluem:

- **Precisão:** Deteção robusta de partículas pequenas e irregulares.
- **Escalabilidade:** Capacidade de análise em larga escala.
- **Automatização:** Reduz a intervenção manual, otimizando o fluxo de trabalho analítico.

8.1.2 Plataformas de Desenvolvimento

Para a implementação e treino do algoritmo, serão utilizadas bibliotecas de *machine learning* de código aberto, como TensorFlow¹ e PyTorch², agilizando o desenvolvimento do modelo. Estas plataformas oferecem suporte robusto para o desenvolvimento de modelos avançados e a integração com ferramentas de processamento de imagem.

Os conjuntos de dados utilizados para treino e validação do modelo incluirão imagens de microplásticos capturadas em condições controladas conforme explanado no fluxograma 7.1.

¹TensorFlow é uma biblioteca de código aberto amplamente utilizada para a construção e treino de modelos de *machine learning* e *deep learning*. Para mais informações, visite <https://www.tensorflow.org/>.

²PyTorch é uma biblioteca de código aberto voltada para computação científica e desenvolvimento de redes neurais profundas. Para mais informações, visite <https://pytorch.org/>.

8.1.3 Etiquetagem das Imagens

Uma etapa fundamental no desenvolvimento do modelo de processamento de imagem é a criação de um conjunto de dados robusto e anotado com precisão. Para este fim, foi utilizado o programa *MakeSense*³, uma ferramenta open-source que se destaca pela interface intuitiva e pelos recursos avançados que simplificam o processo de rotulagem de imagens.

Na Figura 8.1, é apresentado um exemplo do processo de etiquetagem realizado no *MakeSense*. Cada microplástico identificado nas imagens foi destacado e rotulado com precisão utilizando caixas delimitadoras (*bounding boxes*) ou formas poligonais, dependendo da complexidade da partícula. Este processo detalhado assegura que o conjunto de dados gerado seja adequado para treinar modelos de *machine learning* com alto nível de confiabilidade e desempenho. A plataforma também facilita a exportação dos dados anotados em diversos formatos compatíveis com frameworks como TensorFlow e PyTorch garantindo flexibilidade no desenvolvimento do modelo.



Figura 8.1: Exemplo do processo de etiquetagem de microplásticos utilizando a plataforma *MakeSense*. Cada microplástico identificado é destacado e rotulado com precisão, permitindo a criação de um conjunto de dados anotados para o treino de modelos de *machine learning*.

8.1.4 Processo de Etiquetagem

O processo de etiquetagem segue os seguintes passos:

- **Carregamento das Imagens:** As imagens são carregadas no *MakeSense*, garantindo a compatibilidade e qualidade dos dados.
- **Rotulagem:** As partículas de microplásticos são identificadas e delimitadas com caixas delimitadoras (*bounding boxes*).
- **Exportação dos Dados:** Os dados anotados são exportados em formato YOLO, necessário para treinar o modelo de *machine learning*.

³Disponível em: <https://www.makesense.ai/>

8.2 Justificação das Escolhas Tecnológicas

A decisão de iniciar o projeto pela componente de processamento de imagem reflete a necessidade de estabelecer uma base sólida para a solução proposta. A escolha do *MakeSense* como ferramenta para a etiquetagem de imagens, bem como a abordagem inicial exclusivamente digital, fundamenta-se nos seguintes critérios:

- **Impacto Científico e Técnico:** A utilização de análise e classificação de microplásticos baseada em imagens representa um avanço significativo na compreensão da extensão da poluição marinha. Esta abordagem proporciona dados mais precisos e abrangentes, apoiando o desenvolvimento de estratégias eficazes de mitigação e preservação ambiental.
- **Interface Intuitiva do *MakeSense*:** A simplicidade da interface do *MakeSense* facilita a etiquetagem, permitindo o uso por operadores com diferentes níveis de experiência técnica e reduzindo significativamente o tempo necessário para a rotulagem.
- **Flexibilidade e Compatibilidade:** A ferramenta *MakeSense* suporta formatos amplamente utilizados em projetos de *machine learning*, como COCO JSON, Pascal VOC e YOLO, e permite integração direta com frameworks populares, como TensorFlow e PyTorch.
- **Viabilidade Técnica e Económica:** A implementação inicial, focada no desenvolvimento de algoritmos de processamento de imagem, reduz custos e simplifica a operacionalização, evitando a necessidade de recursos físicos complexos nas fases iniciais.
- **Adaptabilidade Futura:** Os algoritmos desenvolvidos nesta fase poderão ser ajustados para diferentes ambientes e integrados a sistemas de hardware em fases posteriores do projeto, garantindo escalabilidade e flexibilidade na aplicação prática.

8.3 Aplicação das Áreas Científicas e Disciplinas

O desenvolvimento do algoritmo de processamento de imagem envolve conhecimentos de várias áreas científicas e disciplinas do curso, nomeadamente:

- **Ciência de Dados e Machine Learning:** Aplicação de técnicas avançadas para a deteção de microplásticos.
- **Computação:** Implementação e otimização de algoritmos para análise de imagens.
- **Gestão de Projetos:** Organização e monitorização do progresso das etapas do TFC.

8.4 Perspetivas Futuras

Embora o foco imediato deste TFC seja o desenvolvimento de um algoritmo de processamento de imagem eficiente para a deteção de microplásticos, o projeto apresenta um horizonte de expansão que inclui a integração de uma infraestrutura de hardware em fases futuras. Esta evolução visa combinar o modelo computacional com dispositivos físicos, como câmaras digitais microscópicas e sensores auxiliares, para permitir a aplicação prática em ambientes marinhos e fluviais.

A implementação do componente hardware não será abordada no âmbito temporal deste trabalho, mas constitui uma oportunidade promissora para a continuidade do projeto. Este avanço poderá complementar a análise computacional com dados recolhidos em tempo real, promovendo uma solução completa e escalável para a monitorização ambiental.

Além disso, a adaptação do sistema às necessidades específicas de diferentes ambientes e a integração com plataformas de monitorização em tempo real serão áreas estratégicas a explorar. A perspetiva de transformar esta solução numa ferramenta acessível e replicável reforça o seu potencial impacto, alinhando-se com os objetivos de desenvolvimento sustentável e preservação ambiental.

Capítulo 9

Calendário

9.1 Planeamento Detalhado

Com base nos progressos e desafios identificados, o plano de trabalho foi ajustado para priorizar atividades críticas e garantir a conclusão do TFC dentro do prazo estipulado. As etapas principais incluem:

- **Desenvolvimento do Algoritmo de Processamento de Imagem:** Iniciar o modelo utilizando abordagens de *machine learning*, com foco em aumentar a precisão na deteção de microplásticos.
- **Validação com Dados Reais:** Recolher dados adicionais, incluindo imagens simuladas e reais, para melhorar a robustez do modelo.
- **Documentação Técnica:** Preparar relatórios intermediários e a versão final do relatório, detalhando os resultados alcançados, desafios e perspectivas futuras.

9.2 Cronograma

A Figura 9.1 apresenta o cronograma em formato Gantt, detalhando as atividades de forma sequencial e destacando as dependências entre tarefas. Este planeamento visual ajuda a monitorizar o progresso e a identificar possíveis atrasos ou necessidades de ajuste.




Figura 9.1: Cronograma Gantt do plano de trabalho remanescente.

9.3 Acompanhamento e Reavaliação

Dada a natureza do projeto, o progresso será monitorizado continuamente para garantir o cumprimento dos prazos e a qualidade dos resultados. O cronograma será revisto periodicamente para acomodar novas descobertas ou desafios, promovendo uma abordagem flexível e adaptativa.

9.4 Conclusão

Este capítulo delinea uma visão clara e estruturada das atividades necessárias para a conclusão do TFC, priorizando tarefas críticas e estabelecendo prazos realistas. Apesar das dificuldades enfrentadas, os ajustes realizados no plano inicial oferecem uma abordagem prática e eficiente. O trabalho realizado até agora, combinado com a implementação cuidadosa do plano de ação, proporciona uma base sólida para alcançar os objetivos propostos, permitindo também que o projeto possa ser continuado por outros alunos no futuro.

Bibliografia

- [Pro20] United Nations Environment Programme. *An Assessment Report on Issues of Concern: Chemicals and Waste Issues Posing Risks to Human Health and the Environment - September 2020*. 2020. URL: <https://wedocs.unep.org/20.500.11822/33807>.
- [Cam+24] Maximiliano Campos-Lopez et al. “Advancing Microplastic Detection Technology through Digital Image Processing, Fractal Analysis, and Polynomial Approximation Methods”. Em: *Microscopy Microanalysis 2024 N/A* (2024), ozae044–195.
- [Pra+19] Joana Correia Prata et al. “Methods for sampling and detection of microplastics in water and sediment: A critical review”. Em: *TrAC Trends in Analytical Chemistry* 110 (2019), pp. 150–159. ISSN: 0165-9936. DOI: <https://doi.org/10.1016/j.trac.2018.10.029>. URL: <https://www.sciencedirect.com/science/article/pii/S0165993618305247>.
- [Pra+20] Joana Correia Prata et al. “Environmental exposure to microplastics: An overview on possible human health effects”. Em: *Science of The Total Environment* 702 (2020), p. 134455. ISSN: 0048-9697. DOI: <https://doi.org/10.1016/j.scitotenv.2019.134455>. URL: <https://www.sciencedirect.com/science/article/pii/S0048969719344468>.
- [Red+16] Joseph Redmon et al. “You Only Look Once: Unified, Real-Time Object Detection”. Em: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 779–788. DOI: 10.1109/CVPR.2016.91.
- [Jia+22] Peiyuan Jiang et al. “A Review of Yolo Algorithm Developments”. Em: *Procedia Computer Science* 199 (2022). The 8th International Conference on Information Technology and Quantitative Management (ITQM 2020 2021): Developing Global Digital Economy after COVID-19, pp. 1066–1073. ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2022.01.135>. URL: <https://www.sciencedirect.com/science/article/pii/S1877050922001363>.
- [Du18] Juan Du. “Understanding of Object Detection Based on CNN Family and YOLO”. Em: *Journal of Physics: Conference Series* 1004 (abr. de 2018), p. 012029. DOI: 10.1088/1742-6596/1004/1/012029.
- [Won+19] Alexander Wong et al. “YOLO Nano: a Highly Compact You Only Look Once Convolutional Neural Network for Object Detection”. Em: dez. de 2019, pp. 22–25. DOI: 10.1109/EMC2-NIPS53020.2019.00013.
- [UNR21] UNRIC. *Campanha Mares Limpos: Dentro da luta contra os microplásticos*. Acessado em 30 de novembro de 2024. 2021. URL: <https://unric.org/pt/campanha-mares-limpos-dentro-da-luta-contra-os-microplasticos/>.
- [Ser21] Copernicus Marine Service. *Detetar poluição plástica nos oceanos*. Acessado em 30 de novembro de 2024. 2021. URL: <https://marine.copernicus.eu/pt/servicos/plastico-poluicao/detetar-poluicao-plastica>.